

DEBATE ARENA — экономика прогона

2 конференции по 2 дня · 3 000 + 2 000 гостей · цены: 4 июня 2026 (OpenRouter API, live)

Исходные допущения

10 запросов к модели на 1 бой (3 раунда + судья + финал)	~7 200 токенов на бой (6 000 вход + 1 200 выход)	420 боев — базовый сценарий (120 + 90 боев/день × 2 дня)	840 боев — пиковый сценарий (2 ринга / плотный поток)
---	---	---	--

Число боев ограничено пропускной способностью ринга (~3–4 мин/бой, ~80–120 боев/день на один экран), а не числом гостей: 5000 человек физически не успеют сыграть больше. При базовом сценарии это ~3.02 млн токенов за оба мероприятия — мизер для любой платной модели.

Стоимость по сценариям

Модель / тариф	Цена \$/1М (вх/вых)	За 1 бой	Базовый (420)	Пиковый (840)
Free (gpt-oss, qwen:free и т.п.) Жёсткие rate-limit (429), часто «No backends». На потоке 5000 гостей нестабильно — нужен платный фоллбэк.	\$0/\$0	\$0.0000/бой	\$0.0000	\$0.0000
Qwen Flash (qwen3.5-flash) Самая дешёвая из вменяемых. Быстрая, реплики бойцов тянет; для судьи слабовата.	\$0.065/\$0.26	\$0.0007/бой	\$0.295	\$0.590
DeepSeek V3.2 Отличный баланс цена/качество. Хорошо держит русский и JSON судьи.	\$0.229/\$0.343	\$0.0018/бой	\$0.750	\$1.50
Qwen3.5-397B-A17B Флагман Qwen3.5 (397B, MoE A17B, контекст 262k). Топ-качество дебатов и судейства.	\$0.39/\$2.34	\$0.0051/бой	\$2.16	\$4.32
Claude Haiku 4.5 (API) Pay-as-you-go. Дешёвый Claude, качество выше Qwen Flash.	\$1/\$5	\$0.012/бой	\$5.04	\$10.08
Claude Sonnet 4.x (API) Pay-as-you-go. Премиум-качество и стабильность.	\$3/\$15	\$0.036/бой	\$15.12	\$30.24
Claude Max (20×) — подписка ⚠ Подписка Max привязана к Claude.ai/Claude Code и НЕ доступна по API для внешнего приложения. Для арены технически не подходит; цена дана как «если бы». Плюс лимиты использования.	\$200/мес	\$200.00/мес	\$400.00	\$400.00

Вывод и рекомендация

- Токены здесь почти ничего не стоят. Даже флагманская Qwen3-235B обходится в единицы долларов за оба мероприятия, а Qwen Flash / DeepSeek — в районе \$0.3–1.5 суммарно. Узкое место — не деньги, а скорость и стабильность.
- Оптимум: бойцы на Qwen Flash или DeepSeek V3.2, судья и финал — на DeepSeek/Qwen3-235B (он арбитр, важно качество). Итог: \$1–3 за обе конференции.
 - Премиум-вариант: всё на Claude Sonnet API — стабильно и качественно, всё равно лишь ~\$15–30 суммарно (pay-as-you-go).
 - Закладывай платный фоллбэк в любом случае: один прайм-тайм на 3000 гостей убьёт бесплатные лимиты.

Про «Claude Max подписку»: тариф Max ($\approx \$200/\text{мес}$) рассчитан на работу в Claude.ai и Claude Code и **не предоставляет API-ключ для внешнего веб-приложения** — для аренды он технически непригоден. Вдобавок $\$200\text{--}400$ — это в 10–100 раз дороже, чем pay-as-you-go под нашу нагрузку. Подписку брать не нужно.

Допущения по токенам — из механики боя и реальных замеров теста test-fight-integrity. Цены OpenRouter — live из API на дату выше; Claude — публичный прайс (Haiku 4.5 $\$1/\5 , Sonnet 4.x $\$3/\15 , Max 20x $\approx \$200/\text{мес}$). Фактический расход $\pm 20\text{--}30\%$ в зависимости от длины персон и настроек памяти бойцов.